### **FST**

FST(Finite State Transducer)算法的概念在这篇博客中并不涉及,网上有太多的资料啦,写的都非常的不错。这里推荐这位网友的介绍:<a href="https://www.shenyanchao.cn/blog/2018/12/04/lucene-fst/">https://www.shenyanchao.cn/blog/2018/12/04/lucene-fst/</a>。如果链接失效了,可以看附件中的副本。本文中,我们基于一个例子来介绍在Lucene中如何实现FST算法及应用,感谢网友关新全的分享,基于他的分享使得我在看源码的时候事半功倍,在此基础上,增加一些更加贴近源码的内容。同样的关新全同学分享的文章在附件中。

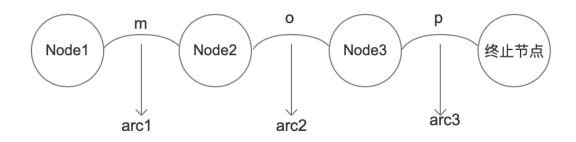
## 准备工作

先介绍几个重要的类跟变量

#### Arc< T>类

每一个Arc< T>对象封封装了某个我们需要存储的数据,并且每一个Arc< T>对象属于某一个Node对象,一个Node对象可以包含多个一个Arc< T>对象,用Arc< T>[] 数组的方式存储,终止节点是没有Arc< T>对象的。Node类的子类有UnCompiledNode< T>类跟CompiledNode 类,下文中会介绍

```
public static class Arc<T> {
   public int label;
   public Node target;
   public boolean isFinal;
   public T output;
   public T nextFinalOutput;
}
```

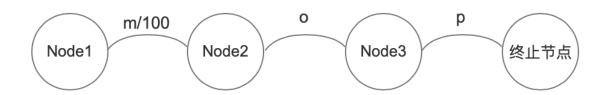


例如 "mop",会使用三个Arc<T>对象来分别描述"m","o","p"的三个字符的信息,并且这三个对象属于三个不同的Node,如上图中,描述"m"的Arc<T>对象arc1,它属于Node1节点,对象arc1中的label的值是 109,即"m"的ASCII值;对象arc1的target的值即Node2,这里暂时不讨论isFinal、nextFinalOutput的含义,后面会涉及,下面介绍下output的值:

output值是一个输入的附加值,比如有输入"mop",它的附加值是100,但是对于分别封装了"m","o","p"的三个arc对象,附加值100应该存放哪个arc对象的output字段呢?下面通过一个例子来说明:

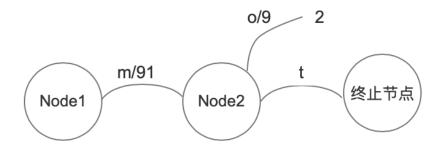
例子: 输入为 "mop", "mt", 附加值分别是100跟91。

#### 处理"mop", 100



只处理输入"mop"时,附加值是放在"m"的arc对象中。

#### 处理"mt", 91



上图中我们能发现,如果后面的输入跟前一个输入有相同的前缀,那么相同前缀对应的每一个arc的output都有可能被更新,在这个例子中,"mop"的附加值100被拆分为91跟9,因为"mt"的附加值是91,取两者的较小值来更新封装了"m"的arc对象中的output值。

上图中封装了"p"的arc怎么没有了,多出了一个值2 ? 这里不用关心这一点,下文会解释。

#### BytesStore bytes;

在这里,我们只需要知道在BytesStore类中有一个current[]数组,它用来存放四种数据来描述一个arc的信息:

#### index

当前arc对象描述的字符不是数据的最后一个字符时,会存储一个index值来指向下一个字符在current[]数组中的位置。

#### output

arc的output字段的值,如果output为0,那么就不用存储,在查询阶段,会对一个term的所有arc的output值进行整合,合成一个完整的值。

#### label

label值即我们的输入数据,比如我们的输入"mop",对应三个label值,其中的一个label值就是109,即"m"的ASCII值。

#### flag

flag的值用来在读取构建后的FST时使用,它用来描述一个arc的信息,在当前版本7.5.0中, flag有以下的值:

BIT FINAL ARC: 1 arc指向一个终止节点

BIT LAST ARC: 2 arc是Node节点中的最后一个arc

BIT\_TARGET\_NEXT: 4 上一个UnCompiledNode< T>类型的Node处理结束后新生成的CompiledNode类型的Node是当前arc的target结点,用来描述当前的arc封装的字符不是数据的最后一个字符

BIT\_STOP\_NODE: 8 arc的target是一个终止节点
BIT ARC\_HAS\_OUTPUT: 16 arc有output值(output不为0)

BIT\_ARC\_HAS\_FINAL\_OUTPUT: 32 arc有output值,并且output的值是最终的值(下文会解释)

### UnCompiledNode< T>类;

前面的图中 Node1, Node2, Node2都是UnCompiledNode<T>类的对象,即节点。节点中可以包含多个arc,并且arc的信息未存放到current[]数组中。

### CompiledNode类;

CompiledNode类描述了一个arc的信息已经被写入到current[]数组中,比如上图中消失的那个封装了"p"的arc对象,以及多出的值2,这个值2描述了在current[]数组中存储封装了"p"的arc对象的数据的下标位置。

#### NodeHash< T>类

NodeHash< T>类提供了对节点的Hash存储,目的就是减少空间占用,每次对一个UnCompiledNode< T>对象处理前,先判断之前有没有处理过(判断Hash值是否一致),如果有,那么就不用存储到current[]数组中,实现了后缀存储功能。

## UnCompiledNode< T>[] frontier;

存放UnCompiledNode< T>类对象的数组,即存放节点的数组。上文中的图中的Node1, Node2, Node3都是frontier[]数组的数组元素

# long lastFrozenNode;

构建FST时,每次处理完一个节点,就会返回一个long类型的值,如果是 终止节点那么返回固定值 -1,否则返回在current[]数组中的下标值。

## 算法基本步骤

步骤1:处理上一个输入与当前输入不相同Node节点,将Node节点中的所有arc对象的信息写入到current[]数组中,如果是第一个输入,直接执行下一个步骤。 步骤2:将当前输入写入到frontier[]数组中。 步骤3:处理上一个输入与当前输入相同的前缀值,调整output值。

## 例子

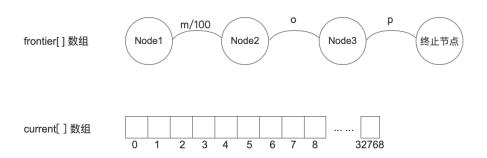
下面通过一个例子来介绍FST的构建跟查询,输入跟附加值如下:

```
String[] inputValues = {"mop", "moth", "pop", "star", "stop", "top"};
long[] outputValues = {100, 91, 72, 83, 54, 55};
```

注意的是输入顺序必须是有序的,才能获得一个最小FST。例子中的输入已经默认有序的

# 输入mop

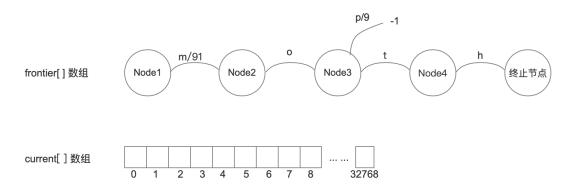
这是第一个输入, 所以没有写入current[]数组的操作。



## 输入moth

输入moth后,我们要处理上一个输入"mop"的不相同的结点,可以看出不相同的节点是前一张图中Node3后面一个终止节点,所以要将这个节点的所有arc信息写入到current[]数组中,并获得一个在current[]中的下标值,从代码层面描述就是将 UnCompiledNode<T>对象变成CompiledNode对象,由于是终止节点,没有arc对象,所以返回值是固定值 -1。并且这个值不需要写入到current[]数组中,最后更新lastFrozenNode为 -1

以上执行的步骤1跟步骤2,剩下执行步骤3,更新Node1中"m"的附加值,由100变成91。并且"p"的附加值由0变为9。

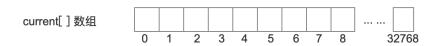


## 输入pop

输入pop后,与上一个值没有相同的结点,所以我们要将Node2,Node3,Node4,终止节点的所有arc信息写入到current[]数组中,注意的是Node1中的所有arc只有在所有输入处理结束后才会处理。所有的处理的顺序为: 节点间按照从后往前,节点内的arc按照写入到该结点时候的顺序,在当前情况下,处理的arc顺序应该是: 终止节点->Node4(h) -> Node3(p -> t) ->Node2(o)

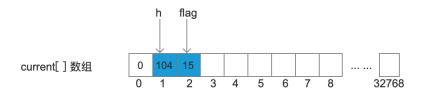
### 处理终止节点

终止节点返回值为固定值-1,并更新lastFrozenNode为 -1。current[]数组不变



#### 处理Node4 (h)

Node4中只有"h"对应的arc对象,根据flag的定义,这个arc对象,它满足Node4节点中的最后一个arc(BIT\_LAST\_ARC)、arc的target结点的值跟lastFrozenNode一致都为-1(BIT\_TARGET\_NEXT)、arc指向一个终止节点(BIT\_FINAL\_ARC)、arc的target是一个终止节点(BIT\_STOP\_NODE)、所以flag的值为 BIT\_LAST\_ARC(2) + BIT\_TARGET\_NEXT(4) + BIT\_FINAL\_ARC(1) + BIT\_STOP\_NODE(8) = 15。然后将flag跟"h"的ASCII值写入到current[]数组中,最后更新lastFrozenNode的值为2,该值为flag在current[]数组中的下标值。



### 处理Node3 (p -> t)

由于UnCompiledNode<T>类中使用 Arc<T>[] 数组存储所有的arc, 所以按照存储到该数组的先后顺序进行处理。同时也意味着"t"对应的arc是Node3中的最后一条arc。

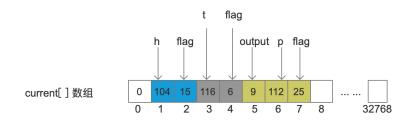
#### 处理 "p"

"p"对应的arc对象,它满足 arc指向一个终止节点(BIT\_FINAL\_ARC)、arc的target是一个终止节点(BIT\_STOP\_NODE)、arc有output值(9)(BIT\_ARC\_HAS\_OUTPUT)、所以flag的值为BIT\_FINAL\_ARC(1) + BIT\_STOP\_NODE(8) + BIT\_ARC\_HAS\_OUTPUT(16) = 25。由于还有其他arc未处理,所以暂时不能更新lastFronzenNode的值。

#### 处理"t"

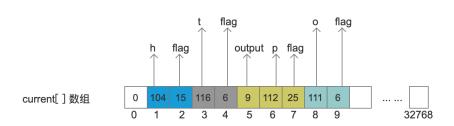
"t"对应的arc对象,它满足 Node3节点中的最后一个arc(BIT\_LAST\_ARC)、arc的target结点的值跟 lastFrozenNode是相同的(2)(BIT\_TARGET\_NEXT)所以flag的值为 BIT\_LAST\_ARC(2) + BIT\_TARGET\_NEXT(4) = 6。Node3中所有的arc处理结束,更新lastFronzenNode的值为7,7是Node3的第一个arc的flag在current[]数组中的下标。

这里有个注意点就是,当按照 p -> t的顺序处理结束后,会对刚才存储的数据执行逆置操作。所以"t"跟"p"对应的arc对象的数据在current[]数组中的位置就如下图:

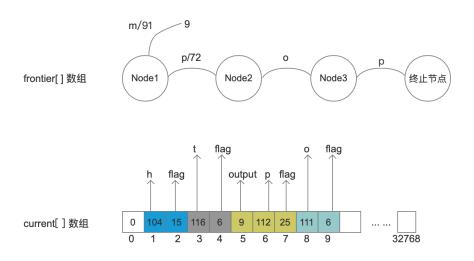


#### 处理Node2(o)

"o"对应的arc对象,它满足 Node2节点中的最后一个arc(BIT\_LAST\_ARC)、arc的target结点的值跟 lastFrozenNode是相同的,所以flag的值为 BIT\_LAST\_ARC(2) + BIT\_TARGET\_NEXT(4) = 6。更新 lastFronzenNode的值为9。 注意的是,由于"m"对应的arc的target是指向"o",所以它的target会被 更新为 9



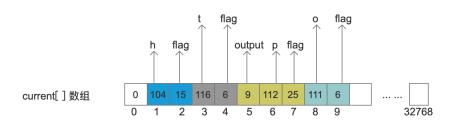
步骤一执行结束后,把"pop"添加到frontier[]数组中,如下图:



## 输入 star

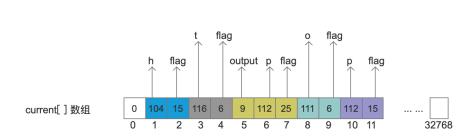
输入star后,与上一个值没有相同的结点,所以我们要将Node2,Node3,终止节点的所有arc信息写入到current[]数组中,同样的是Node1中的所有arc只有在所有输入处理结束后才会处理。所有的处理的顺序为: 节点间按照从后往前,节点内的arc按照写入到该结点时候的顺序,在当前情况下,处理的arc顺序应该是: 终止节点 -> Node3(p)->Node2(o)

### 处理终止节点



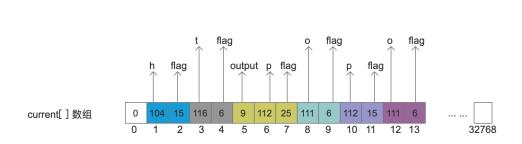
### 处理Node3(p)

"p"对应的arc对象,它满足 Node3节点中的最后一个arc(BIT\_LAST\_ARC)、arc指向一个终止节点(BIT\_FINAL\_ARC)、arc的target结点的值跟lastFrozenNode是相同的(BIT\_TARGET\_NEXT)、arc的target是一个终止节点(BIT\_STOP\_NODE)、所以flag的值为 BIT\_FINAL\_ARC(1) +
BIT\_LAST\_ARC(2) + BIT\_TARGET\_NEXT(4) + BIT\_STOP\_NODE(8) = 15。

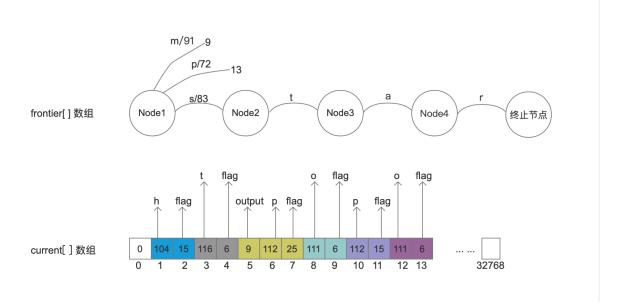


### 处理Node2 (o)

这个过程就不赘述, 跟上面的逻辑没区别

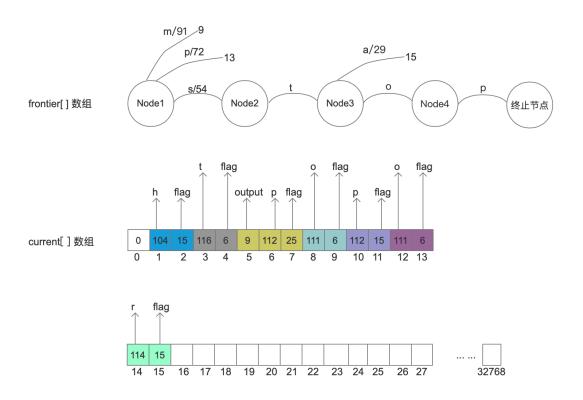


#### 将"star"写入到frontier[]数组中



# 输入stop

#### 这个过程就不赘述了, 跟上面的逻辑没区别



# 输入top

输入top后,与上一个值没有相同的结点,所以我们要将Node2,Node3,Node4,终止节点的所有arc信息写入到current[]数组中,注意的是Node1中的所有arc只有在所有输入处理结束后才会处理。所有的处理的顺序为: 节点间按照从后往前,节点内的arc按照写入到该结点时候的顺序,在当前情况下,处理的arc顺序应该是: 终止节点->Node4(p) -> Node3(a -> o) ->Node2(t)

#### 处理终止节点

终止节点返回值为固定值-1,并更新lastFrozenNode为 -1。current[]数组不变

#### 处理Node4 (p)

处理"p"对应的arc对象时,根据NodeHash提供的后缀存储发现,之前存储"pop"的第二个"p"对应的UnCompiledNode<T> 类型的对象Hash值相同,所以这里直接就可以使用已经处理(compile)过的的CompiledNode对象,所以current[]没有改变。

#### 处理Node3 (a->o)

#### 处理"a"

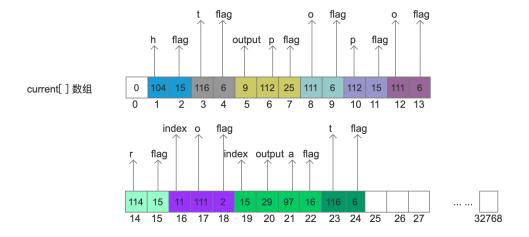
"a"对应的arc对象,它满足 arc有output值(29) 所以flag的值是BIT\_ARC\_HAS\_OUTPUT(16) = 16, 另外a的target的值是大于0的,说明"a"不是数据的最后一个字符,这个值描述下一个字符在current[]数 组中的位置15,值为。

#### 处理"o"

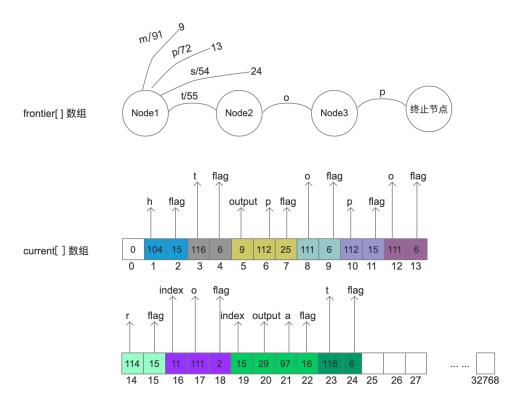
"o"对应的arc对象,它满足 Node3节点中的最后一个arc(BIT\_LAST\_ARC),所以flag的值是2,另外a 的target的值是大于0的,说明"o"不是数据的最后一个字符,这个值描述下一个字符在current[]数组中的位置,值为11。

#### 处理Node2 (t)

"t"对应的arc对象,它满足 Node2节点中的最后一个arc(BIT\_LAST\_ARC)、arc的target结点的值跟 lastFrozenNode是相同的(BIT\_TARGET\_NEXT),所以falg的值为 BIT\_LAST\_ARC(2) + BIT TARGET NEXT(4) = 6。最后更新lastFrozenNode的值为24。

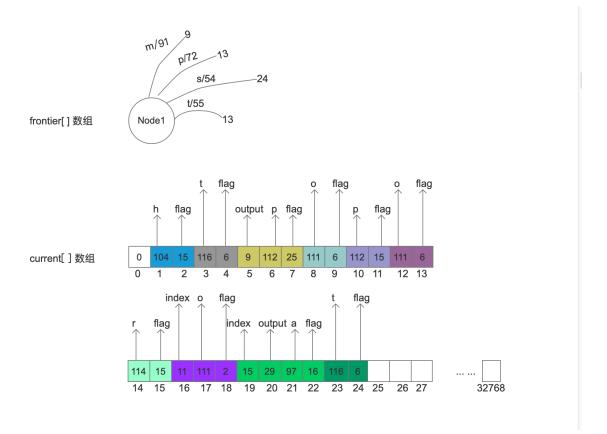


#### 将"top"写入到frontier[]数组中



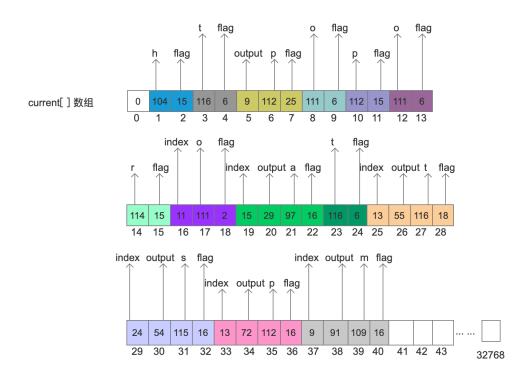
# 处理top

"top"是最后的输入,所以在将"top"写入到frontier[]数组后,直接处理,处理过程不赘述,跟上面的逻辑没什么区别,由于"top"跟"pop"有2个相同的后缀值,所以处理完"top"后,current[]数组没有变化



## 最后处理Node1节点

不赘述, 跟前面的逻辑是差不多的



本篇博客介绍了FST的构建过程,在随后的博客中会介绍如何使用current[]数组来恢复数据。

<u>点击下载</u>Markdown文件